Introducción al Análisis de Datos

Estadística

Este es el conteo mensual de llamaradas solares de clase C (pequeñas llamaradas frecuentes en el Sol que generalmente tienen impactos mínimos en la Tierra) observadas en un período de 12 meses en dos ciclos solares diferentes.

1D
Dataset A (Ciclo Solar X)

A = {25, 27, 24, 25, 26, 23, 24, 26, 25, 24, 26 , 25}

1D
Dataset B (Ciclo Solar Y)

B = {35, 12, 48, 5, 20, 40, 15, 38, 10, 45, 2, 30}

0. Preparar los datos

a. ordenar

A = {23, 24, 24, 24, 25, 25, 25, 25, 26, 26, 26, 27}

B = {2, 5, 10, 12, 15, 20, 30, 35 ,38, 40, 45, 48}

b. contar

$n_A = 12$

$n_B = 12$

c. sumar todos los elementos

$S_A = 300$

$S_B = 300$

1. Medidas de tendencia central

a. media

n elementos: $x_1, x_2, \ldots, x_n$, podemos calcular la media $(\bar{x})$

$$\bar{x} = \frac{x_1 + x_2 + \ldots + x_n}{n}$$

→ sumatoria (Σ)

$$\sum_{i=1}^{n} x_i = \underset{\uparrow \atop i=1}{x_1} + x_2 + \ldots + \underset{\uparrow}{x_n}$$

$$\bar{x} = \frac{\sum x_i}{n}$$

$$\left.\begin{aligned} \bar{X}_A &= \frac{300}{12} = 25 \\ \bar{X}_B &= \frac{300}{12} = 25 \end{aligned}\right\} \checkmark$$

b. mediana

El valor central de un dataset ordenado que separa la mitad inferior de la mitad superior

→ impar

$$x_1, x_2, x_3, x_4, x_5$$

$$\text{mediana} = x_3$$

→ par

$$x_1, x_2, x_3, x_4, x_5, x_6$$

$$\text{mediana} = \frac{x_3 + x_4}{2}$$

$$\left.\begin{aligned} &\bullet\ \text{mediana}_A = \frac{25+25}{2} = 25 \\ &\bullet\ \text{mediana}_B = \frac{20+30}{2} = 25 \end{aligned}\right\} \checkmark$$

c. Moda

Es el dato que más se repite

- $\text{moda}_A = 25$
- no tenemos para B.

Medidas de dispersión

- Histograma

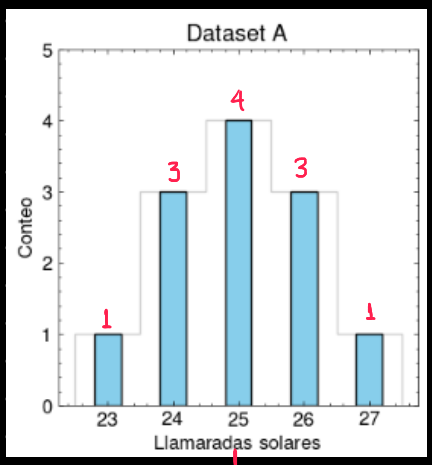

25

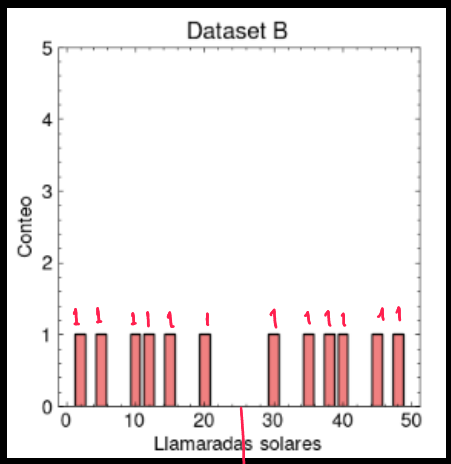

25

- ¿Qué tan lejos está cada dato de la media?

$$\text{desviación} = x_i - \bar{x}$$

Si un mes tuvimos 35 llamaradas, tendremos una desviación de +10
Si un mes tuvimos 15 llamaradas, tendremos una desviación de -10

suma de todos las desviaciones $\sum_{i=1}^{n} (x_i - \bar{x})$

A = {23, 24, 24, 24, 25, 25, 25, 25, 26, 26, 26, 27} $\bar{x} = 25$

$$\sum (x_i - \bar{x}) = (x_1 - \bar{x}) + (x_2 - \bar{x}) + (x_3 - \bar{x}) + (x_4 - \bar{x}) + (x_5 - \bar{x}) + (x_6 - \bar{x}) + (x_7 - \bar{x})$$
$$+ (x_8 - \bar{x}) + (x_9 - \bar{x}) + (x_{10} - \bar{x}) + (x_{11} - \bar{x}) + (x_{12} - \bar{x})$$
$$= (23-25) + (24-25) + (24-25) + (24-25) + (25-25) + (25-25) + (25-25)$$
$$+ (25-25) + (26-25) + (26-25) + (26-25) + (27-25)$$
$$= \cancel{-2} \cancel{-1} \cancel{-1} \cancel{-1} + 0 + 0 + 0 + 0 \cancel{+1} \cancel{+1} \cancel{+1} \cancel{+2}$$
$$= 0$$

$$\rightarrow \sum (x_i - \bar{x}) = 0$$

Vamos a utilizar el cuadrado de las desviaciones $\forall x \in \mathbb{R},\ x^2 \geq 0$

$$(x_i - x)^2 \geq 0$$

a. varianza (σ^2)

Al sumar todas las desviaciones al cuadrado y dividir para el número total de elementos n podemos encontrar el promedio de la distancia al cuadrado

$$\sigma^2 = \frac{\sum (x_i - x)^2}{n}$$

Tiene una limitación importante, sus unidades están al cuadrado

longitud (m), σ^2 (m^2)

llamaradas σ^2 (llamaradas^2)

b. desviación estándar (σ)

$$\sqrt{\sigma^2} = \sigma = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$$

ciclo X

- $\sigma_A \approx 1.08$

ciclo Y

- $\sigma_B \approx 15.53$

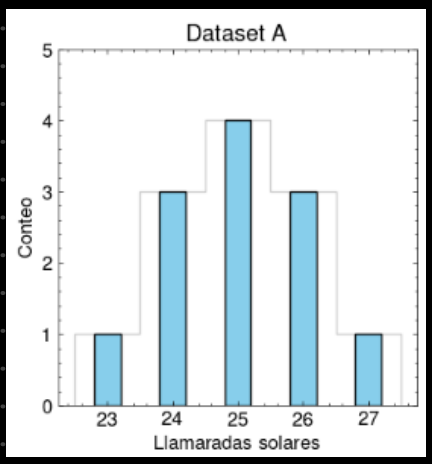

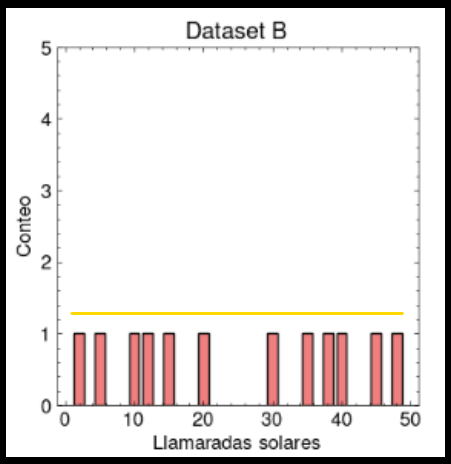

Algo de álgebra

Vamos a establecer una identidad. Por definición

$$\sum_{i=1}^{n} 1 = 1 + 1 + 1 + \dots + 1 = n$$

$$\sum_{i=1}^{n} 1 = n$$

Observemos la media

$$\bar{x} = \frac{\sum x_i}{n} \longrightarrow \sum x_i = n\bar{x}$$

Volvamos al cuadrado de la desviación

$$\sum (x_i - \bar{x})^2 = \sum (x_i^2 - 2x_i\bar{x} + \bar{x}^2)$$

→ propiedad de la sumatoria, α (número real, constante) x_i (dataset X), y_i (dataset Y)

$$\sum (\alpha x_i + y_i) = \alpha \sum x_i + \sum y_i$$

constante constante

$$\sum (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = \sum x_i^2 - \sum (2x_i\bar{x}) + \sum \bar{x}^2$$

$$= \sum x_i^2 - 2\bar{x} \sum x_i + \bar{x}^2 \sum 1$$

$$= \sum x_i^2 - 2\bar{x}(n\bar{x}) + \bar{x}^2(n)$$

$$= \sum x_i^2 - 2n\bar{x}^2 + n\bar{x}^2$$

$$\sum (x_i - \bar{x})^2 = \sum x_i^2 - n(\bar{x})^2$$

↳ varianza

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{1}{n}\left(\sum x_i^2 - n(\bar{x})^2\right)$$

$$= \frac{\sum x_i^2}{n} - (\bar{x})^2$$

- $x_i\,(X)$, $y_i\,(Y)$

$$\bar{x} = \frac{\sum x_i}{n} \qquad \bar{y} = \frac{\sum y_i}{n}$$

$$\sum x_i = n\bar{x} \qquad \sum y_i = n\bar{y}$$

c. Covarianza

¿Cuál es la relación entre estas dos variables?

$$\text{cov}(x,y) = \sum [(x_i - \bar{x})(y_i - \bar{y})]$$

- $\text{cov}(x,y) > 1$, relación positiva
- $\text{cov}(x,y) < 1$, relación negativa
- $\text{cov}(x,y) = 0$, no hay relación

$\text{cov}(x,y) < 1$ $\quad$ $\text{cov}(x,y) = 0$ $\quad$ $\text{cov}(x,y) > 1$

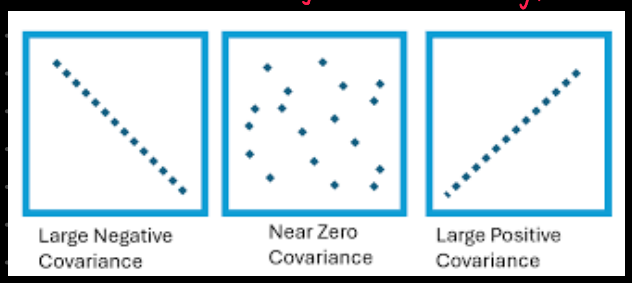

x aumenta
y disminuye

x aumenta
y aumenta

$$(x_i - \bar{x})(y_i - \bar{y})$$

$$= x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x}\bar{y}$$

const. $\quad$ const. $\quad$ const.

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - \sum x_i \bar{y} - \sum \bar{x} y_i + \sum \bar{x}\bar{y}$$

$$= \sum x_i y_i - \bar{y}\sum x_i - \bar{x}\sum y_i + \bar{x}\bar{y}\sum 1$$

$$= \sum x_i y_i - \bar{y}(n\bar{x}) - \bar{x}(n\bar{y}) + n\bar{x}\bar{y}$$

$$= \sum x_i y_i - n\bar{x}\bar{y} - \cancel{n\bar{x}\bar{y}} + \cancel{n\bar{x}\bar{y}}$$

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y}$$

Regresión lineal

Edwin Hubble descubrió que las galaxias se alejan de nosotros a una velocidad proporcional a su distancia.

$$v = H_0 \cdot d$$

Podemos medir distancias utilizando candelas estándar, mientras que las velocidades son inferidas a partir del redshift espectral.

	Distancia (Mpc)	Velocidad (km/s)
1	11	1050
2	20	1400
3	28	1850
4	36	2750
5	45	3050
6	54	3950
7	66	4550
8	73	5450
9	87	5900
10	96	7050
11	110	7600
12	122	8350

Dataset 2D

- Encontrar una relación entre las cantidades

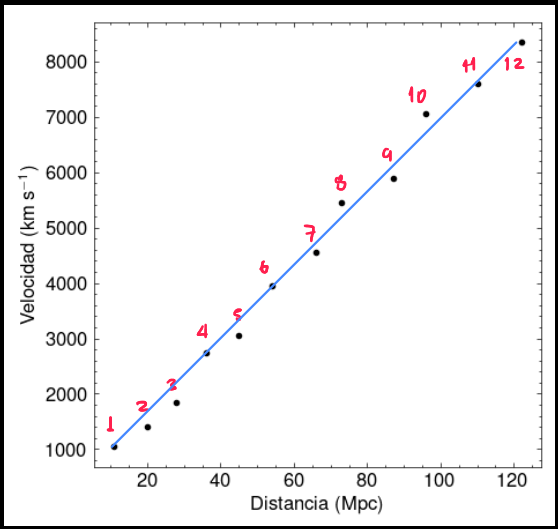

¿Cómo puedo modelar esta relación?

¿Hay alguna forma de descubrir una ecuación que relacione distancia y velocidad?

→ relación lineal

→ ecuación de la recta $\quad y = mx + b$

intersección con el eje y

pendiente

x_i → distancia $\qquad$ velocidad predicha $\quad m x_i + b$

y_i → velocidad "real"

$$r_i = y_i - (mx_i + b)$$

Suma de los cuadrados de los residuos

$$S = \sum [y_i - (mx_i + b)]^2 = \sum (y_i - mx_i - b)^2$$

Nuestra misión es minimizar esta suma, obtener el mínimo valor posible.

Método de mínimos cuadrados

$$S(m,b) \qquad \frac{\partial S}{\partial m} = -2\sum x_i(y_i - mx_i - b) = 0 \qquad \frac{\partial S}{\partial b} = 2\sum (y_i - mx_i - b) = 0$$

① $\sum x_i (y_i - mx_i - b) = 0$

$$\sum (x_i y_i - m x_i^2 - b x_i) = 0$$

$$\sum x_i y_i - m \sum x_i^2 - b \sum x_i = 0$$

② $\sum (y_i - mx_i - b) = 0$

$$\sum y_i - m \sum x_i - b \sum 1 = 0$$

$$n\bar{y} - mn\bar{x} - bn = 0$$

$$\bar{y} - m\bar{x} - b = 0$$

$$\boxed{b = \bar{y} - m\bar{x}}$$

$$\sum x_i y_i - m \sum x_i^2 - (\bar{y} - m\bar{x}) n\bar{x} = 0$$

$$\sum x_i y_i - m \sum x_i^2 - n\bar{x}\bar{y} + mn\bar{x}^2 = 0$$

$$\sum x_i y_i - m\left(\sum x_i^2 - n\bar{x}^2\right) - n\bar{x}\bar{y} = 0$$

$$\boxed{m = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}}}$$